Guion del video: Reconocimiento de prendas con CNN y Fashion MNIST

Duración sugerida: 9 a 10 minutos
Integrantes: [Integrante 1] e [Integrante 2]
Formato: grabación de pantalla (Zoom, Meet u OBS) con cámaras encendidas durante la presentación y la demo.

> Cada integrante debe aparecer y hablar. Lean el guion como guía, no palabra por palabra: suena más natural con sus propias palabras. Reemplacen los valores entre corchetes por sus resultados reales.

Resumen de tiempos

Tiempo	Sección	Responsable	En pantalla
0:00 – 0:45	Introducción	Integrante 1	Diapositiva de título con nombres
0:45 – 1:45	Dataset	Integrante 1	Muestra de imágenes del dataset
1:45 – 3:00	Metodología	Integrante 2	Notebook: carga, división, entrenamiento
3:00 – 4:45	Arquitecturas	Integrante 2 (modelos 1 y 2) e Integrante 1 (modelo 3)	Esquemas o código de los 3 modelos
4:45 – 6:15	Resultados y comparación	Integrante 2	Tabla comparativa, curvas, matriz de confusión
6:15 – 8:15	Demo de la aplicación	Integrante 1 (explica) e Integrante 2 (muestra las prendas)	Aplicación con cámara en vivo
8:15 – 9:15	Mejoras	Integrante 1	Diapositiva de mejoras
9:15 – 9:45	Cierre	Ambos	Diapositiva final

1. Introducción (0:00 – 0:45) — Integrante 1

En pantalla: diapositiva de título con el nombre del proyecto, el curso y los integrantes.

Guión:

"Hola, somos [nombres] y en este video presentamos nuestro tercer parcial de [curso]. El reto fue construir un sistema de reconocimiento de prendas de vestir usando Deep Learning con el dataset Fashion MNIST.

Entrenamos tres arquitecturas diferentes de redes neuronales convolucionales, las comparamos con métricas objetivas, seleccionamos la mejor y la integramos en una aplicación que usa la cámara del computador para reconocer la prenda en tiempo real, mostrando la predicción y su nivel de confianza. Vamos a recorrer el proceso completo."

2. El dataset (0:45 – 1:45) — Integrante 1

En pantalla: la cuadrícula de imágenes de ejemplo que genera el notebook (una por clase) y la tabla de las 10 clases.

Guión:

"Fashion MNIST es un dataset de Zalando con 70.000 imágenes en escala de grises de 28 por 28 píxeles: 60.000 para entrenamiento y 10.000 para prueba. Tiene 10 clases: camiseta, pantalón, suéter, vestido, abrigo, sandalia, camisa, zapatilla, bolso y botín, perfectamente balanceadas, con 6.000 imágenes por clase en entrenamiento.

Una característica importante es que todas las prendas están centradas, con fondo negro y la prenda en tonos claros. Más adelante veremos por qué esto condiciona el diseño de nuestra aplicación con cámara."

3. Metodología (1:45 – 3:00) — Integrante 2

En pantalla: celdas del notebook de división de datos y de entrenamiento (callbacks).

Guión:

"Dividimos los datos en 54.000 imágenes de entrenamiento, 6.000 de validación y 10.000 de prueba. La normalización está dentro del propio modelo, lo que evita errores entre el entrenamiento y la aplicación final. También aplicamos aumento de datos leve, con volteos, traslaciones, zoom y rotaciones pequeñas, para que el modelo tolere las variaciones de una cámara real.

Para que la comparación fuera justa, los tres modelos usan exactamente el mismo protocolo: optimizador Adam, batch de 128, hasta 30 épocas, con Early Stopping y reducción automática de la tasa de aprendizaje. Evaluamos en el conjunto de prueba con accuracy, precision, recall, F1-score, matriz de confusión, número de parámetros y tiempos."

4. Arquitecturas (3:00 – 4:45) — Integrante 2 e Integrante 1

En pantalla: el resumen (`model.summary()`) o un esquema simple de cada arquitectura.

Guión (Integrante 2):

"La primera es una CNN simple, nuestra línea base: dos bloques de convolución con max pooling, una capa densa de 128 neuronas y dropout. Tiene [X] parámetros.

La segunda es una CNN profunda al estilo VGG: tres bloques de dos convoluciones cada uno, con 32, 64 y 128 filtros, añadiendo Batch Normalization y Dropout para estabilizar el entrenamiento y reducir el sobreajuste. Tiene [X] parámetros."

Guión (Integrante 1):

"La tercera es una Mini-ResNet, con bloques residuales: cada bloque suma su entrada a su salida mediante una conexión de atajo, lo que facilita el flujo del gradiente y permite más profundidad con menos parámetros. Usa Global Average Pooling en lugar de aplanar, y tiene [X] parámetros.

Así tenemos tres enfoques distintos: una red básica, una red profunda regularizada y una red residual."

5. Resultados y comparación (4:45 – 6:15) — Integrante 2

En pantalla: tabla `comparacion_modelos.csv`, gráfica de barras, curvas de aprendizaje y matriz de confusión del mejor modelo.

Guión:

"Estos son los resultados en el conjunto de prueba. La CNN simple alcanzó [X] % de accuracy, la CNN profunda [X] % y la Mini-ResNet [X] %. En F1 macro, los valores fueron [X], [X] y [X].

El mejor modelo fue [nombre], porque [razón: mayor F1, buen balance entre precisión y costo computacional, etc.]. Su tiempo de inferencia es de [X] milisegundos por imagen, suficiente para tiempo real.

En la matriz de confusión vemos que las clases más difíciles son [camisa, suéter, camiseta y abrigo], porque visualmente son muy parecidas, mientras que pantalón, bolso y botín casi no se confunden. Las curvas de aprendizaje muestran [poco / algo de] sobreajuste: [comentar la brecha entre entrenamiento y validación]."

6. Demo de la aplicación (6:15 – 8:15) — Integrante 1 (explica) e Integrante 2 (muestra las prendas)

En pantalla: terminal ejecutando `python app_camara.py` y la ventana de la cámara.

Guión de explicación:

"La aplicación está hecha con OpenCV y TensorFlow. Abre la cámara y muestra un recuadro central donde ponemos la prenda. Como Fashion MNIST tiene prendas claras sobre fondo negro, la aplicación procesa cada imagen: la pasa a grises, segmenta la prenda con el umbral de Otsu, la recorta, la centra, la ajusta al formato de 28 por 28 y la pasa al modelo. En la esquina se ve la miniatura exacta que recibe la red.

Arriba aparece la predicción, el porcentaje de confianza y las tres clases más probables. Si la confianza es menor a 60 %, la aplicación indica que la predicción es incierta."

Secuencia de la demostración (ensayarla antes):

1. Mostrar una **camiseta** sobre fondo liso: comentar la clase y la confianza.
2. Mostrar una **zapatilla** o un **zapato**.
3. Mostrar un **bolso o morral**.
4. Mostrar un **pantalón** o un **suéter / chaqueta**.
5. Mostrar una prenda difícil (camisa) y comentar si se confunde con camiseta o suéter, explicando por qué.
6. Mostrar un objeto que no es prenda (por ejemplo, un cuaderno) y comentar que el modelo igual clasificará en alguna de las 10 clases, con confianza variable.
7. Presionar **S** para guardar una captura y **Espacio** para congelar la predicción.

Guión de comentario sobre limitaciones:

"Notamos que funciona mejor con fondo liso, buena luz y la prenda bien centrada. Con fondos complejos o sombras fuertes la precisión baja, porque el modelo fue entrenado con fotos de catálogo y no con imágenes de una webcam. Esa diferencia entre el dominio de entrenamiento y el real es una de las principales limitaciones."

7. Posibles mejoras (8:15 – 9:15) — Integrante 1

En pantalla: diapositiva con lista corta de mejoras.

Guión:

"Identificamos varias mejoras posibles. Primero, reducir la diferencia entre el dataset y la cámara real, creando un dataset propio con fotos de la webcam y haciendo fine-tuning, o aumentando los datos con cambios de brillo, contraste y ruido. Segundo, mejorar la segmentación con un modelo de remoción de fondo en lugar de umbralización clásica.

Tercero, usar transfer learning con modelos como MobileNet o EfficientNet y mayor resolución. Cuarto, calibrar la confianza y detectar objetos que no pertenecen a las 10 clases. Y por último, optimizar hiperparámetros, convertir el modelo a TensorFlow Lite para despliegue ligero, o crear una interfaz web."

8. Cierre (9:15 – 9:45) — Ambos

Integrante 2: "En conclusión, entrenamos y comparamos tres CNN, y el modelo [nombre] logró el mejor desempeño con [X] % de accuracy."

Integrante 1: "Lo integramos en una aplicación que reconoce prendas en tiempo real con su nivel de confianza, y aprendimos la importancia del preprocesamiento y del domain shift."

Ambos: "En la carpeta de Drive entregamos el notebook, el código de la aplicación, el informe técnico y este video. Gracias por su atención."

Lista de verificación antes de grabar

- Ejecutar el notebook completo y tener a la mano la tabla de resultados, las curvas y la matriz de confusión.
- Probar `app_camara.py` con las prendas reales que se usarán; preparar un fondo liso (una pared o cartulina) y buena iluminación.
- Tener 4 o 5 prendas listas: camiseta, zapato, bolso, pantalón, suéter.
- Cerrar notificaciones y otras ventanas; verificar audio y que la ventana de la cámara se vea completa.
- Ensayar una vez completo con cronómetro para ajustar la duración.
- Subir el video, el informe y el código a una subcarpeta con los nombres de los integrantes en la carpeta de Drive indicada.